Ne Kadar Emin? Belirsizlik ve Modelin Sınanması

Hafta 4 ·Alan ve Öğrenen Modeli: Sistem Ne Biliyor, Ne Kadar Emin?

Bu bölümün sorusu: "Model öğrenenin bildiğini söylüyor" cümlesine ne kadar güvenebiliriz?

> NOT **Amaç.** Bu alt başlık Hafta 4 kitap bölümünün bir parçasıdır ve tek başına çalışılabilecek biçimde hazırlanmıştır.

Bu parçanın kazanımları

- "Model emin" ifadesinin iki anlamını, yani olasılık değeri ile modelin güvenilirliğini, birbirinden ayırır.
- Bir öğrenen modelinin sınanmasında kullanılan ölçütlerin, veri bölme yöntemlerinin ve veri toplama yanlılıklarının sonuçları nasıl değiştirdiğini açıklar.

Anahtar sözcükler: Belirsizlik · Dış geçerlik · Çapraz doğrulama · Katılım kaybı yanlılığı · Parametre tutarlılığı

4.4 • Ne Kadar Emin? Belirsizlik ve Modelin Sınanması

Bu haftanın ana sorusundaki "ne kadar emin" ifadesi iki farklı biçimde anlaşılabilir. Birinci anlam modelin kendi çıktısıdır: bilgi izleme "öğrenilmiş olma olasılığı 0,91" der. Bu sayı bir kesinlik değil, bir olasılıktır; sistem 0,95 ölçütünü ustalaşma kararı için seçer, ama 0,91'de olan bir öğrenenin yüz kişiden dokuzunun hâlâ öğrenilmemiş durumda olabileceğini kabul etmiş olur. İkinci anlam daha derindir: bu sayıyı üreten model, parametreleri ve verisi ne kadar güvenilirdir? Birinci anlam hesaplanır; ikinci anlam sınanmak zorundadır.

Birinci anlamın bir yan yüzü, sistemin elindeki kanıtın miktarıdır. Pelánek, Elo sisteminde güncelleme büyüklüğünü belirleyen K sabiti küçükse kestirimin çok yavaş yakınsadığını, büyükse son birkaç yanıta aşırı ağırlık verdiği için kararsız olduğunu anlatır. Bu yüzden çoğu Elo uzantısı sabit K yerine bir belirsizlik işlevi kullanır: yeni bir öğrencinin becerisi çok belirsizdir ve güncellemeler büyük olmalı, veri biriktikçe küçülmelidir (2016, Bölüm 2.3). Pelánek'in aktardığı örneklerden birinde belirsizlik işlevi $U(n) = a/(1 + bn)$ biçimindedir; n yanıtlanan soru sayısıdır ve a = 1, b = 0,05 değerleri kullanılmıştır (2016, Bölüm 2.3). İlke şudur: **bir sistem, çok az kanıta dayanan kestirimini çok kanıta dayananla aynı güvenle sunmamalıdır.** Panelde "yüzde doksan altı" yazan bir sistem, bu sayının kaç yanıta dayandığını da göstermelidir.

İkinci anlama Corbett ve Anderson'ın kendi çalışması iyi bir örnektir, çünkü yazarlar modeli iki ayrı biçimde sınar. İç geçerlik, modelin sistem içindeki adımlarda doğru yanıt olasılığını ne kadar iyi tahmin ettiğidir. Dış geçerlik ise modelin öğrenen yardım almadan çalıştığı testteki performansı ne kadar öngördüğüdür; yazarlar bunun asıl önemli soru olduğunu söyler (1995, s. 267). İlk deneyde sabit parametrelerle model ile veri arasındaki ilişki orta düzeyde kalmış (r = 0,47) ve ortalama mutlak hata 0,16 çıkmıştır; parametrelerin kural başına serbest bırakılmasıyla ilişki 0,85'e yükselmiştir (Corbett ve Anderson, 1995, s. 264). İkinci deneyde model, ustalaşmış sayılan öğrencilerin hepsini aynı bilgi durumunda gördüğü için ilk iki testte bireysel farkları ayırt edememiştir; oysa öğrencilerin sistemdeki hata oranı ikinci test başarısıyla anlamlı biçimde ilişkilidir (r = −0,64) ve bireysel farklar sürmektedir (Corbett ve Anderson, 1995, s. 269). Yazarlar bu sorunun bireysel farkların modelde yer almamasından kaynaklandığını açıklar ve her öğrenci için parametre ağırlıkları ekler (s. 270). Son deneyde (Deney 4) gerçek test başarısı model tahmininden yüzde 5–10 düşüktür (s. 273). Ayrıca öğrencilerin bilgi olasılığı 0,95–1,00 aralığında olmasına karşın bazıları sontestte neredeyse yüzde 40 hata yapmıştır; yazarlar bu durumu esas olarak sürçme parametresindeki bireysel farklılıkla ilişkilendirir (s. 275).

Bu bulgular, vinyetteki Fatma Hanım'ın durumunu bir model hatası olarak okumamızı sağlar. Sistem içinde yüksek bilgi olasılığı, sistem dışında aynı başarıyı garanti etmez. 1.4'te Kulik ve Fletcher'ın yerel test ile standart

test arasındaki farkını gördük (2016, s. 60); bilgi izlemenin sistem içi tahmini ile dış testteki başarı arasındaki ayrım aynı sorunun öğrenen modeli düzeyindeki karşılığıdır.

Bir öğrenen modeli bugün araştırmada nasıl sınanır? Pelánek'in derlemesi sonuçları değiştirebilecek dört ayrıntıya dikkat çeker.

Tablo 4.7 · Bir model raporunu okurken sorulacak sorular

Soru	Neden önemli?	Kaynak
Hangi ölçüt kullanılmış?	Sıralama ölçütü (AUC) yalnızca tahminlerin göreli sırasına bakar; politika mutlak değerleri kullanıyorsa anlamlı olmayabilir. İstatistiksel olarak anlamlı ama çok küçük doğruluk farkları pratikte önemsiz olabilir.	Pelánek (2017, Bölüm 6.1)
Veri nasıl bölünmüş?	Dizisel veride rastgele bölme geçmişi tahmin etmek için geleceği kullanmak demektir; yeni öğrenenlere genelleme asıl ilgi konusudur.	Pelánek (2017, Bölüm 6.3)
Veri nasıl toplanmış?	Ustalaşan öğrencinin sistemden çıkması gibi katılım kaybı yanlılıkları, parametre değerlerini ve model karşılaştırmasını etkiler.	Pelánek (2017, Bölüm 6.4)
Parametreler tutarlı mı?	Yorumlanacak parametreler farklı eğitim kümelerinde farklı çıkabilir; eyleme dönük içgörü için tutarlılık analizi gerekir.	Pelánek (2017, Bölüm 6.2)

Uyarlanır veri toplamanın bir yan etkisi özellikle öğreticidir. Öğrencilere uygun zorlukta maddeleri seçen uyarlanır bir sistemle toplanan veride çok basit bir temel model bile iyi tahmin doğruluğuna ulaşır ve modeller arası farklar küçülür, oysa farklı modellerin uygulamadaki sonuçları büyük olabilir; çünkü veri toplama ile öğrenen modellemesi arasında bir geri besleme döngüsü oluşmuştur (Pelánek, 2017, Bölüm 6.4). Pelánek'in 2016 tarihli çalışmasındaki benzetim sonucu da aynı yöne işaret eder: maddeler uyarlanır biçimde seçildiğinde basit doğru oranı yöntemi madde zorluğunu kötü kestirir ve öğrenci sayısı arttıkça da düzelmez, oysa Elo sistemi daha ağır bir yöntemle (eşzamanlı en çok olabilirlik kestirimi) hemen hemen aynı sonucu verir (Bölüm 3.2). Çıkarım şudur: uyarlanır sistemlerin verisiyle yapılan öğrenen modeli değerlendirmeleri, sistemin kendi kararlarından etkilenmiştir. Bir ürünün "tahmin doğruluğu yüzde seksen beş" iddiası bu nedenle hangi veriyle, hangi bölmeyle ve hangi karşılaştırmayla sınandığı söylenmeden değerlendirilemez.

Pelánek ayrıca bazı modellerin hiç doğru yanıt vermeyen bir öğrenen için bile ustalık öngörebildiğini, bu tür durumlar test verisinde nadir olduğunda doğruluk ölçütünü etkilemeyeceğini, ama kullanıcının sisteme güvenini sarsacağını yazar (2017, Bölüm 6.1).

UYGULAMA **"Ne kadar emin?" için dört kontrol.** Bir ürünün öğrenen modeli hakkında şunları isteyin. (1) Sayının kaç yanıta dayandığını gösteren bir gösterge. (2) Model tahmininin sistem içi mi, sistem dışı bir testle mi sınandığı. (3) Sınamanın yeni öğrenenlerde mi, aynı öğrenenlerin eski verisinde mi yapıldığı. (4) Veri uyarlanır bir sistemden geldiyse bunun sonuca etkisinin tartışılıp tartışılmadığı.

Bu parçada kullanılan kaynaklar

Corbett, A. T. ve Anderson, J. R. (1995). Knowledge tracing: Modeling the acquisition of procedural knowledge. User Modelling and User-Adapted Interaction, 4(4), 253–278. https://doi.org/10.1007/BF01099821

Kulik, J. A. ve Fletcher, J. D. (2016). Effectiveness of intelligent tutoring systems: A meta-analytic review. Review of Educational Research, 86(1), 42–78. https://doi.org/10.3102/0034654315581420

Pelánek, R. (2016). Applications of the Elo rating system in adaptive educational systems. Computers & Education, 98, 169–179. https://doi.org/10.1016/j.compedu.2016.03.017

Pelánek, R. (2017). Bayesian knowledge tracing, logistic models, and beyond: An overview of learner modeling techniques. User Modeling and User-Adapted Interaction, 27(3–5), 313–350. https://doi.org/10.1007/s11257-017-9193-2