OULAD: Bir Açık Veri Setini Okumak

Hafta 5 ·Öğrenme Analitiği ve Kestirim: Veriden Göstergeye, Göstergeden Eyleme

Bu bölümün sorusu: Gerçek bir açık veri seti ne içerir, nasıl derlenmiştir ve bu seçimler ne sonuç doğurur?

> NOT **Amaç.** Bu alt başlık Hafta 5 kitap bölümünün bir parçasıdır ve tek başına çalışılabilecek biçimde hazırlanmıştır.

Bu parçanın kazanımları

- Açık Üniversite Öğrenme Analitiği Veri Seti'nin (OULAD) tablolarını, anahtarlarını, seçilim ve anonimleştirme özelliklerini okuyarak bir veri setinin neyi gösterip neyi göstermediğini değerlendirir.

Anahtar sözcükler: OULAD · Modül-sunum · Anahtar sütun · Seçilim · Anonimleştirme

5.3 • OULAD: Bir Açık Veri Setini Okumak

Analitik kavramlar soyut kalınca "gösterge" bir yönetici sunumu sözcüğüne dönüşür. Bu yüzden derste gerçek bir veri setiyle çalışırız: Kuzilek, Hlosta ve Zdrahal'ın (2017) yayımladığı Open University Learning Analytics Dataset, kısaca OULAD. Veri seti, Birleşik Krallık'taki Açık Üniversite'nin 22 dersinden (modül-sunumundan), 32.593 öğrenciden, öğrencilerin değerlendirme sonuçlarından ve çevrimiçi öğrenme ortamındaki etkileşimlerinin günlük tıklama özetlerinden (10.655.280 kayıt) oluşur (Kuzilek vd., 2017, s. 1). Yazarlar, veri setini ayırt eden özelliğin demografik veri ile toplulaştırılmış tıklama verisini birlikte içermesi olduğunu belirtir (s. 1). Veri seti CC-BY 4.0 lisansıyla serbestçe kullanılabilir (s. 1).

Açık Üniversite, dünyanın en büyük uzaktan eğitim üniversitelerinden biridir; dersler "modül" adıyla verilir ve aynı modül yıl içinde birden çok kez sunulabilir. Her sunum, başladığı yıl ve ayla adlandırılır; örneğin "2013J", Ekim 2013'te başlayan sunumdur (Kuzilek vd., 2017, s. 2). Modül bağımsız bir ders ya da bir programın parçası olarak okunabilir ve önceden bir yeterlik şartı yoktur (s. 2). Bu, veri setini yetişkin eğitimi açısından ilginç kılar: kayıt koşulları esnektir ve öğrenen kitlesi heterojendir. Öğrenenler yaklaşık yirmi kişilik çalışma gruplarında örgütlenir, her grubun bir tutor'u vardır; tipik bir sunum dokuz ay sürer (s. 2).

Tablo 5.3 • OULAD'ın ana tabloları

Tablo	Ne tutar?	Bağlantı anahtarı	Bu derste neden önemli?
studentInfo	Demografi ve her modül-sunum için son sonuç (final_result)	code_module, code_presentation, id_student	Kestirilecek sonucun ve alt grupların kaynağı
studentVle	Öğrenenin çevrimiçi ortamdaki günlük tıklamaları (date, sum_click)	code_module, code_presentation, id_student, id_site	Etkileşim izi; göstergelerin ham maddesi
studentAssessment	Teslim edilen değerlendirmelerin puanı ve teslim günü	id_assessment, id_student	Ödev teslimi ve puan gösterge adayları
assessments	Değerlendirme türü (TMA, CMA, sınav), son gün ve ağırlık	code_module, code_presentation, id_assessment	Kilometre taşları ve sunum takvimi
studentRegistration	Kayıt ve kayıt silme tarihi	code_module, code_presentation, id_student	Bırakma zamanı
vle ve courses	Ortam materyalleri ve sunum uzunluğu	id_site; code_module, code_presentation	Materyal türüne göre iz ayrımı

Tablonun sütun adları Kuzilek ve arkadaşlarının tablo tanımlarından alınmıştır (2017, s. 4–6): studentInfo'da 32.593 satır, studentVle'de 10.655.280 satır, assessments'ta 206 satır, studentAssessment'ta 173.912 satır bulunur.

Tablolar tanımlayıcı sütunlarla bağlanır; öğrenci veri setinin merkezindedir (s. 4). studentVle'deki `date` sütunu etkileşimin gününü, `sum_click` ise öğrenenin o gün o materyalle kaç kez etkileşime girdiğini gösterir (s. 6). Sonuç değişkeni `final_result`, kayıt silenler için "Withdrawal" değerini taşır (s. 5); veri dosyasını indirdiğinizde bu sütunun gerçek değerlerini kendi gözünüzle kontrol edin.

> UYGULAMA **Bir gösterge, bir birleştirme.** OULAD üzerinde "ilk 28 günde toplam tıklama" göstergesini üretmek için üç adım yeter. (1) studentVle'de `date` değeri 28'den küçük kayıtları süzün. (2) `code_module`, `code_presentation` ve `id_student` üçlüsüne göre `sum_click` değerlerini toplayın. (3) Bu özet tabloyu aynı üçlü anahtarla studentInfo'ya bağlayıp `final_result` ile yan yana koyun. Anahtarın üç sütundan oluşması rastlantı değildir: aynı öğrenci kimliği farklı modül-sunumlarda yer alabilir, bu yüzden tek sütunla bağlamak satırları yanlış eşleştirebilir. Bu bölümde sayı vermiyoruz; sayıyı atölyede kendi dosyanızdan siz üreteceksiniz.

Bir veri setini kullanmadan önce nasıl derlendiğini bilmek gerekir. Kuzilek ve arkadaşları verinin kurum veri ambarından alındığını, üç tür veri ayırt ettiklerini belirtir: demografik, performans ve öğrenme davranışı (s. 3). Seçim kuralları şunlardır: seçilen sunumda 500'den fazla öğrenci bulunması, modülün en az iki sunumunun olması, çevrimiçi ortam verisinin mevcut olması ve modülde anlamlı sayıda kalan öğrenci bulunması (s. 4). Bu ölçütlerle 4'ü fen-teknoloji-mühendislik-matematik, 3'ü sosyal bilimler olmak üzere yedi modül seçilmiş ve seçilen modüllerdeki toplam öğrenci sayısı 38.239 olmuştur (s. 4).

Son ölçüt bizi uyarmalıdır: modüller, **kalan öğrencisi çok olduğu için** seçilmiştir. Bu bir hata değil, kestirim araştırması için makul bir tercihtir; ama sonuçların her derse taşınabileceği anlamına gelmez. Beşinci soru, yani "Kimin için, nereye kadar?", verinin seçilimine de uygulanır: bu veri seti, özellikle kalma sorunu olan, büyük, birden çok kez sunulan ve çevrimiçi desteği olan dersleri temsil eder.

Anonimleştirme de bir seçim sonucudur. Kişisel kimlik bilgileri (kimlik numarası, doğum tarihi) çıkarılmış, modül adları anlamsız simgelerle değiştirilmiş ve tüm zaman bilgileri sunum başlangıcına göre göreli ifade edilmiştir (Kuzilek vd., 2017, s. 4). Cinsiyet, yoksunluk bandı, en yüksek eğitim düzeyi, yaş, bölge ve engellilik "yarı tanımlayıcı" nitelikler sayılmış, k-anonimlik ölçütü k = 5 olarak uygulanmış ve bu işlem öğrenci sayısını 32.593'e düşürüp yaş ve yoksunluk bandını genelleştirmiştir (s. 4). Yani veri seti, kimliklendirmeyi önlemek için bazı öğrencileri dışarıda bırakmış ve bazı nitelikleri kabalaştırmıştır. Ayrıca Açık Üniversite öğrencilere analitik araştırmaları için veri kullanımından çıkma (opt-out) seçeneği sunmamaktadır (s. 2); bu, yetişkin öğrenenin faillik ve rıza açısından tartışılabilecek bir noktasıdır.

Brooks ve Thompson da OULAD'ı, izin ve erişim koşulları nedeniyle kurum verisine ulaşamayan araştırmacılar için kullanılabilecek önceden oluşturulmuş açık veri setlerinden biri olarak anar (2022, s. 31). Bu hafta atölyede OULAD'dan tek bir modülün bir sunumunu alıp erken bir etkileşim göstergesi üreteceksiniz; ders sonunda elinizde sayılar olacak, ama onları yorumlama kuralları 5.4 ve 5.5'te verilecek.

Bu parçada kullanılan kaynaklar

Brooks, C. ve Thompson, C. (2022). Predictive modelling in teaching and learning. C. Lang, G. Siemens, A. F. Wise, D. Gašević ve A. Merceron (Ed.), Handbook of learning analytics içinde (2. bs., s. 29–37). SoLAR. https://doi.org/10.18608/hla22.003

Kuzilek, J., Hlosta, M. ve Zdrahal, Z. (2017). Open University Learning Analytics dataset. Scientific Data, 4, 170171. https://doi.org/10.1038/sdata.2017.171